Detección y clasificación automática de levaduras de cerveza para el análisis de viabilidad

Noelia Falczuk[1], Luna Sanes[1], Pablo Negri[1,2], Clara Bruzone[3], Diego Libkind[3]

[1] Departamento de Computación, Facultad de Ciencias Exactas y Naturales, Universidad de Buenos Aires, Argentina
[2] Instituto de Investigación en Ciencias de la Computación (ICC, CONICET-UBA), Buenos Aires, Argentina
[3] Centro de Referencia en Levaduras y Tecnología Cervecera (CRELTEC), Instituto Andino Patagónico de Tecnologías Biológicas y Geoambientales (IPATEC, CONICET - UNComahue), Bariloche, Argentina

Introducción

Este proyecto propone un sistema automático de detección y clasificación de levaduras de cerveza a partir de imágenes microscópicas, con el fin de optimizar su reutilización y mejorar el control de calidad en la producción cervecera.

Las herramientas desarrolladas están pensadas para integrarse a la aplicación Microbrew.AR, diseñada específicamente para analizar la viabilidad de las levaduras y su reutilización.

Dataset

Se construyó un conjunto de datos compuesto :

- 50 imágenes microscópicas en condiciones no controladas (Dataset 1).
- Imágenes tomadas en condiciones no controladas por usuarios reales (Dataset 2).
  - Las imágenes corresponden a dos especies con diferentes características morfológicas: Saccharomyces cerevisiae y Saccharomyces eubayanus.

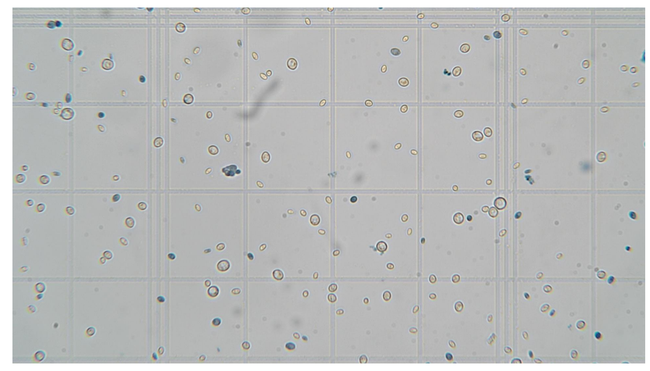

Figura 1: Imagen del Dataset 1.

Preprocesamiento:

- Se extrajeron manualmente regiones de interés (ROI) y se etiquetaron como VIVA o MUERTA.
- Recorte automático del área de análisis para que coincida con el observado por el técnico cervecero.

En total, los datos se componen de:

- Entrenamiento: 12.459 células vivas y 4.531 muertas.
- Testeo: 3.297 vivas y 716 muertas.
  - Si bien hay desbalance en la clasificación, no lo hay para la tarea de detección, ya que ambas clases se agruparán bajo la misma categoría: "célula".

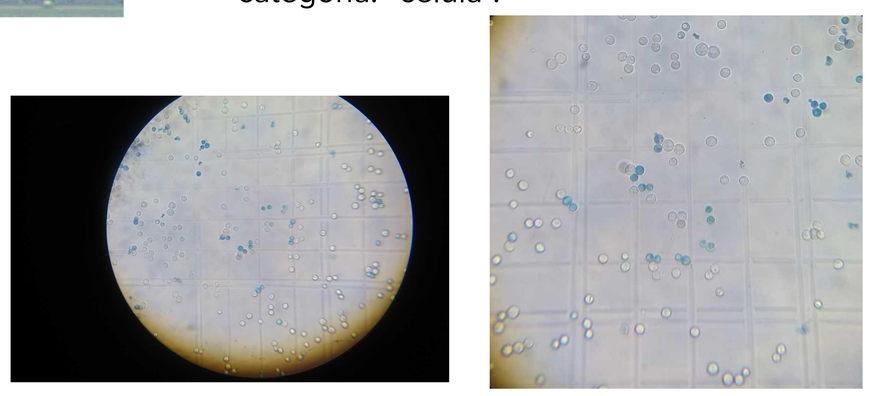

Figura 2: Recorte automático

Detección

Usamos un modelo **YOLOv5**, preentrenado en COCO y ajustado con imágenes blanco y negro del Dataset 1, donde cada ROI fue etiquetada como "célula".

Configuración del modelo

- Se evaluaron distintos umbrales de confianza.
- Se seleccionó 0.45 mínimo aceptable para incluir detecciones en la etapa de clasificación.

Finalmente, se aplicó un proceso progresivo de fine-tuning con el Dataset 2, para mejorar la capacidad de generalización frente a variabilidad no controlada en los datos.

Para mejorar la precisión, se aplicó el método Mean-Shift con el objetivo de eliminar superposiciones entre regiones de interés (ROIs) detectadas múltiples veces. Mean-Shift agrupa detecciones cercanas que representan la misma célula, seleccionando una única posición representativa, asegurando que haya una única ROI detectada por célula.

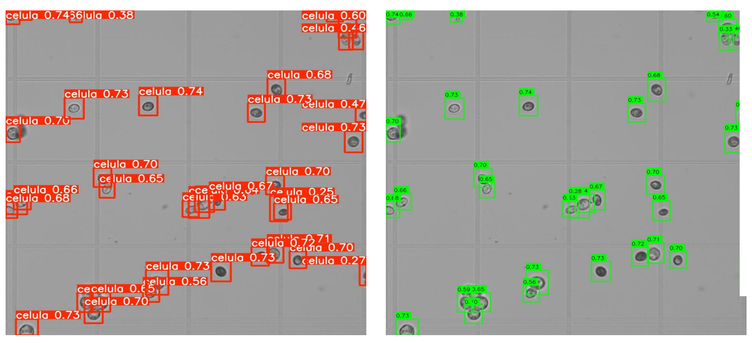

Figura 3: Imagen detectada, y luego de procesada por Mean-Shift

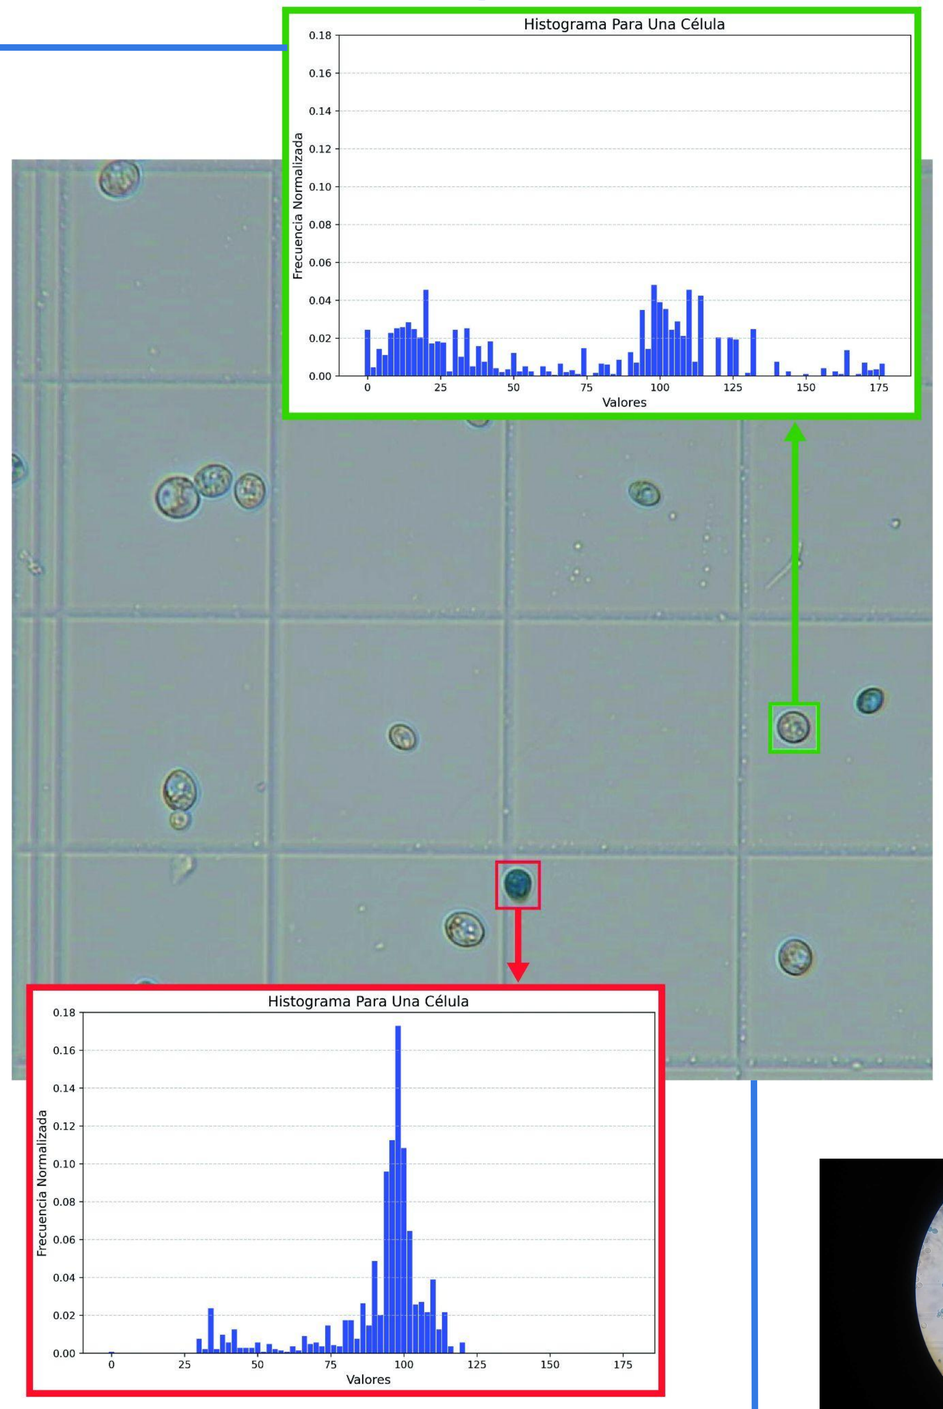

Figura 4: Imagen preprocesada con histogramas para clasificación

Clasificación

- Modelo elegido: **SVM con kernel RBF,** con grid search para determinar demás hiperparámetros.

El proceso de entrenamiento fue el siguiente:

- Se convirtieron las imágenes al espacio de color HSV (Hue, Saturation, Value), bajo la hipótesis de que la separación de color, saturación y brillo podrían ser útiles.
  - Se observa que el canal de saturación presenta una diferenciación de células vivas y muertas.
- Para cada ROI etiquetada manualmente del conjunto de entrenamiento, ya convertidas a HSV, se realiza un histograma normalizado de color, que es la entrada del modelo de clasificación.
- Se entrenaron 2 modelos para testear su performance, uno con canal Hue y el otro con Saturation.

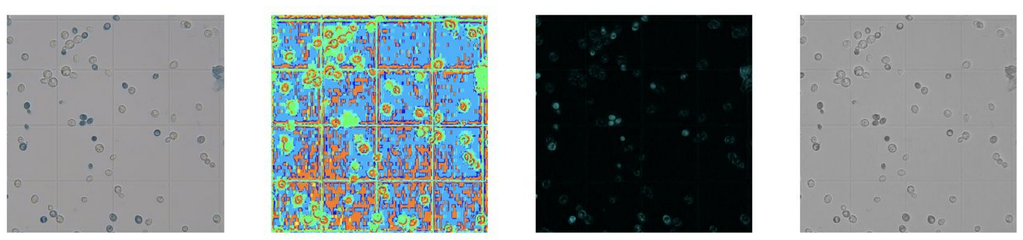

Figura 5: Imagen original, con diferenciación de canales Hue, Saturation y Value.

Para la clasificación de imágenes de testeo, se utilizan las ROI que el modelo de detección arroja, y para cada una de ellas, se determina si es viva o muerta.

Resultados y métricas

Detección

$$\text{Métrica} = \frac{\#\text{células detectadas correctamente}}{\#\text{células detectadas manualmente o células totales}}$$

Se evaluó el proceso de *finetuning* para diferentes grupos de imágenes del Dataset 2, obteniendo la siguiente progresión de métricas.

Etapa	Modelo de Partida	Dataset Utilizado	Métrica
1	Modelo base	Imagenes de laboratorio	0.647
2	Modelo fine-tuneado 1	Primer Grupo	0.845
3	Modelo fine-tuneado 2	Segundo Grupo	0.907
4	Modelo fine-tuneado 3	Tercer Grupo	0.905
5	Modelo fine-tuneado 4	Cuarto Grupo	0.905
6	Modelo fine-tuneado 5	Quinto Grupo	0.984

Tabla 1: Progresión de métricas para modelo de detección

Clasificación

$$\text{Métrica} = \frac{\#\text{células clasificadas correctamente pertenecientes a A}}{\#A}$$

Sea A el conjunto de células detectadas correctamente por el modelo de detección:

	Hue		Saturation	
	SVM	RF	SVM	RF
1	0.897	0.425	0.896	0.590
2	0.891	0.866	0.927	0.871
3	0.893	0.670	0.913	0.746

Tabla 2: Métrica para Dataset 1 y 2, para canales Hue y Saturation

Conclusión

- Se seleccionó, para detección, un modelo YOLO preentrenado, y para clasificación un SVM con histogramas de color, del canal HSV de saturación.
- La integración con la aplicación Microbrew.ar supone una reducción tanto del tiempo necesario para el conteo como del margen de error asociado al factor humano, contribuyendo directamente a la mejora en la calidad de las fermentaciones y a una reutilización más eficiente de los insumos.